

Реконструкция трёхмерных пористых сред с использованием искусственных нейронных сетей

Будалян Я. С.

Научный руководитель: к.т.н., доцент Грачёв Е. А.

Москва, 2019 г.

Введение

- ▶ При моделировании геофизических процессов существует проблема недостаточности знаний о среде, в которой эти процессы протекают. Точные данные доступны из небольшой области (керн - небольшого куска породы, забранного из скважины), а данные компьютерной томографии - из ещё меньшей области (кусочков, вырезанных из керна);
- ▶ Получение дополнительных данных (например, новых кернов, компьютерной томографии) связано с большими затратами. При этом, многие эксперименты по установлению различных характеристик среды в реальности можно провести только один раз для одного керна, поскольку они необратимым образом влияют на него.

Задача реконструкции

Разработка алгоритма реконструкции синтетических образцов пористой среды на основе данных с реального образца. Новые образцы должны сохранять некоторые топологические и статистические свойства реального образца:

▶ $V = \frac{1}{V_{all}} \int_{V_{pore}} dV = \frac{V_{pore}}{V_{all}}$ - пористость

▶ $S = \frac{1}{V_{all}} \int_{\delta V_{pore}} dS$ - удельная площадь поверхности


Задача реконструкции

- ▶ $B = \frac{1}{V_{all}} \int_{\delta V_{pore}} \left(\frac{1}{R_1} + \frac{1}{R_2} \right) dS$ - удельная кривизна поверхности
- ▶ $\xi = \frac{1}{V_{all}} \int_{\delta V_{pore}} \frac{1}{R_1 R_2} dS$ - число Эйлера
- ▶ $S_2(r) = P(x \in P, x + r \in P), \quad x, r \in \mathbb{R}^d$ - двухточечная функция вероятности,

где δV_{pore} - граница двух фаз (среды и пор), P - это вероятность того, что две точки, отстоящие друг от друга на вектор r , принадлежат одной фазе (обе являются порами).

Модельные ограничения

Рассматриваются данные компьютерной томографии керна, состоящего из двух фаз - среды и пор, т. е. томограмма это бинарно-сегментированное трёхмерное изображение.



Образец томограммы керна

Математическая формализация

Задачу реконструкции можно формализовать с помощью вероятностной постановки задачи обучения:

- ▶ Рассматривается многомерное пространство X , содержащее множество всех трёхмерных изображений x : $X = \{x\}$
- ▶ Есть обучающая выборка, состоящая из реальных томограмм $D = \{x_i\}$, $D \subset X$
- ▶ Считается, что D задаёт в X вероятностное распределение $P_X : X \rightarrow [0, 1]$

Математическая формализация

Задача реконструкции трёхмерной пористой среды сводится к синтезу случайного изображения x' из распределения, близкого к задаваемому обучающей выборкой:

$$P_{X'} \approx P_X, \quad x' \sim X'$$

Для моделирования вероятностного распределения P_X предлагается использовать генеративную состязательную нейронную сеть.

GAN

Генеративные состязательные сети (GAN - Generative Adversarial Networks) были придуманы в 2014 году и достигли больших успехов в задачах моделирования сложных распределений.

- ▶ $P_{X'} \approx P_X \Leftrightarrow \rho(P_{X'}, P_X) \longrightarrow \min_{P_{X'}}$
- ▶ $X' = g_\theta(\cdot) \Rightarrow \rho(g_\theta(\cdot), P_X) \longrightarrow \min_\theta$
- ▶ В качестве ρ можно использовать функцию потерь обученного классификатора

GAN

Используются две нейросети:

- ▶ $d_{\zeta}(x)$ - классификатор, дискриминатор
- ▶ $g_{\theta}(x)$ - сеть, трансформирующая входящий шум в элементы множества X' , генератор


Суть использования двух сетей состоит в том, что они обучаются совместно, конкурируя друг с другом.

$$\theta^* = \arg \max_{\theta} \left[\min_{\zeta} L(\zeta, \theta) \right]$$

GAN

Процесс обучения сети GAN принимает следующий вид:

- ▶ Обучается дискриминатор при фиксированном генераторе
- ▶ Обучается генератор при фиксированном дискриминаторе
- ▶ Повторяется до сходимости параметров обеих моделей



Модификация

Использование GAN для реконструкции пористых сред уже исследовалось¹. Однако, главный недостаток предыдущих экспериментов состоит в ручном контроле процесса обучения сетей.

Целью данной работы было:

- ▶ Повторить ранее описанный работоспособный подход
- ▶ Провести модификацию процедуры обучения сетей для устранения необходимости ручного контроля
- ▶ Провести сравнительный анализ результатов с точки зрения сохранения топологических и статистических характеристик реконструированных образцов

¹Lukas Mosser, Olivier Dubrulle и Martin J. Blunt. “Reconstruction of three-dimensional porous media using generative adversarial neural networks”. В: *CoRR* abs/1704.03225 (2017). arXiv: 1704.03225. URL: <http://arxiv.org/abs/1704.03225>.

Обучающая выборка

Обучающая выборка для сети была сформирована путём разрезания компьютерной томограммы песчаника размером 400^3 вокселей на кубики размером 64^3 вокселей с перекрытием в 16 вокселей.






Таблица: Примеры из сформированной обучающей выборки

Результаты

Были проведены вычислительные эксперименты по обучению сетей с модификацией для устранения ручного контроля. Анализ реконструкций был произведён на размерах 64^3 , 216^3 и 360^3 . Для каждого из размеров было получено >500 реконструкций, что позволило построить распределения их характеристик.

Реконструкции 64^3








Таблица: Примеры реконструкций размера 64^3

Реконструкции 64^3



Реконструкции 216^3












Таблица: Примеры реконструкций размера 216^3

Реконструкции 216^3



Реконструкции 216^3 , ручной контроль



Заключение

- ▶ Воспроизведён подход по реконструкции пористой среды с помощью GAN
- ▶ Реализована модификация процесса обучения сети для устранения ручного контроля
- ▶ Получены результаты реконструкций для разных размеров
- ▶ Проведён сравнительный анализ характеристик реконструкций

Полученные результаты показывают, что сеть без ручного контроля обучения успешно обучается и способна реконструировать пористую среду, однако качество реконструкций на размерах больших, чем размер обучающих примеров, получилось хуже, чем для сети с ручным контролем обучения.

Спасибо за внимание!

Задача минимизации

Обучение нейронной сети является задачей многопараметрической минимизации функционала потерь. Для используемых в этой работе сетей данная задача ставится так:

$$\mathcal{L}(\theta, \zeta) = \mathbb{E}_{x \sim p_{data}} \log D_{\zeta}(x) + \mathbb{E}_{z \sim p_z} \log(1 - D_{\zeta}(G_{\theta}(z)))$$

$$\theta^*, \zeta^* = \arg \min_{\theta} \arg \max_{\zeta} \mathcal{L}(\theta, \zeta)$$

Архитектуры G и D

Слой	Размер ядра	Размерность выхода	Кол-во параметров
0_ConvTranspose3d	[256, 512, 4, 4, 4]	[1, 256, 4, 4, 4]	8 388 610
1_BatchNorm3d	[256]	[1, 256, 4, 4, 4]	512
2_ReLU	-	[1, 256, 4, 4, 4]	-
3_ConvTranspose3d	[128, 256, 4, 4, 4]	[1, 128, 8, 8, 8]	2 097 150
4_BatchNorm3d	[128]	[1, 128, 8, 8, 8]	256
5_ReLU	-	[1, 128, 8, 8, 8]	-
6_ConvTranspose3d	[64, 128, 4, 4, 4]	[1, 64, 16, 16, 16]	524 290
7_BatchNorm3d	[64]	[1, 64, 16, 16, 16]	128
8_ReLU	-	[1, 64, 16, 16, 16]	-
9_ConvTranspose3d	[32, 64, 4, 4, 4]	[1, 32, 32, 32, 32]	131 070
10_BatchNorm3d	[32]	[1, 32, 32, 32, 32]	64
11_ReLU	-	[1, 32, 32, 32, 32]	-
12_ConvTranspose3d	[1, 32, 4, 4, 4]	[1, 1, 64, 64, 64]	2 050
13_Tanh	-	[1, 1, 64, 64, 64]	-

Таблица: Архитектура генератора

Архитектуры G и D

Слой	Размер ядра	Размерность выхода	Кол-во параметров
0_Conv3d	[1, 32, 4, 4, 4]	[1, 32, 32, 32, 32]	2 050
1_LeakyReLU	-	[1, 32, 32, 32, 32]	-
2_Conv3d	[32, 64, 4, 4, 4]	[1, 64, 16, 16, 16]	131 070
3_BatchNorm3d	[64]	[1, 64, 16, 16, 16]	128
4_LeakyReLU	-	[1, 64, 16, 16, 16]	-
5_Conv3d	[64, 128, 4, 4, 4]	[1, 128, 8, 8, 8]	524 290
6_BatchNorm3d	[128]	[1, 128, 8, 8, 8]	256
7_LeakyReLU	-	[1, 64, 16, 16, 16]	-
8_Conv3d	[128, 256, 4, 4, 4]	[1, 256, 4, 4, 4]	2 097 150
9_BatchNorm3d	[256]	[1, 256, 4, 4, 4]	512
10_LeakyReLU	-	[1, 256, 4, 4, 4]	-
11_Conv3d	[256, 1, 4, 4, 4]	[1, 1, 1, 1, 1]	16 380
12_Sigmoid	-	[1, 1, 1, 1, 1]	-

Таблица: Архитектура дискриминатора